

Cálculo Numérico Aplicado

Atividade e Programa para casa #4

Prof. Doutor Rafael Gabler Gontijo

25 de maio de 2026

Como formular um problema de otimização?

Para iniciarmos nossos estudos formais no campo da otimização precisamos construir algumas definições preliminares. A primeira delas diz respeito a formulação de um problema de otimização. Em muitos casos formular um problema pode ser até mais difícil do que resolvê-lo. Mais ainda, um problema mal formulado pode acabar demandando um esforço muito maior em sua solução justamente pela falta de clareza na formulação. Eu costumo brincar com meus alunos de Engenharia que diferentemente do treinamento recebido na faculdade, onde os problemas já chegam bem enunciados na forma de provas, listas de exercícios e trabalhos, na vida real o engenheiro deve ser capaz de olhar uma situação concreta, formular o problema a ser resolvido e depois resolvê-lo. Nesse sentido, antes de entrarmos nos métodos, algoritmos e esquemas numéricos destinados à solução de problemas de otimização, precisamos aprender a formular estes problemas.

Um problema típico de otimização é geralmente enunciado da seguinte forma: “*Seja $f(\mathbf{x})$ uma função objetivo e $\mathbf{x}$ um vetor de projeto n -dimensional, desejamos encontrar $\mathbf{x}$ que minimiza ou maximiza $f(\mathbf{x})$ sujeito à $d_i(\mathbf{x}) \leq a_i$ para $i = 1, 2, \dots, m$ e $e_i(\mathbf{x}) = b_i$ para $i = 1, 2, \dots, p$, em que $d_i(\mathbf{x})$ representa um conjunto de restrições expressas por desigualdades, $e_i(\mathbf{x})$ representa um conjunto de restrições expressas por igualdades e a_i e b_i são constantes.*”

No contexto em que $f(\mathbf{x})$, $d_i(\mathbf{x})$ e $e_i(\mathbf{x})$ são funções lineares, o problema de otimização cai na categoria do que chamamos de *programação linear*. Aqui a palavra *programação* possui um sentido mais de planejamento do que propriamente de algoritmo. No contexto em que a função objetivo é quadrática e as restrições são lineares, o problema de otimização é categorizado como um problema de *programação quadrática*. Finalmente, quanto a função objetivo for não linear ou quadrática e as restrições forem não lineares, caímos no campo da *programação não-linear*.

Em muitos contextos os problemas de otimização não estão associados necessariamente à restrições. O exemplo que demos no início dessa seção, associado ao processo de aprendizado de algoritmos de aprendizado de máquina baseado em modelos de linguagem, é um desses tipos de problema. Note que no nosso processo de minimização da entropia cruzada entre os dados de saída fornecidos na etapa de aprendizagem e os dados previstos pelo modelo, não precisamos impor nenhuma restrição ou vínculo à função objetivo.

Dependendo da situação a aplicação de restrições pode complicar muito a solução do problema de otimização. Mas em alguns casos, restrições podem ser facilmente implementadas. Se no nosso problema de otimização da função custo no exemplo dado na seção anterior tivéssemos implementado um condicional para finalização da etapa de treinamento do modelo baseado numa tolerância a ser atingida, essa não deixaria de ser uma restrição, uma vez que essa tolerância certamente estará relacionada aos pesos da matriz W . Nesse caso, a implementação de uma restrição não afetaria a complexidade do algoritmo. Mas em muitos cenários esse não é o caso.

Em contextos de problemas com restrições o ideal é que o número de restrições seja menor ou igual à dimensão do nosso vetor de projeto, ou seja $p + m \leq n$. Quando o problema é formulado de tal sorte que $p + m > n$ dizemos que o problema é super restrito e isso pode ser um problema.

Um outro aspecto interessante de problemas de otimização sem restrições é que podemos apelar à métodos gráficos para compreender melhor o desenvolvimento de métodos numéricos voltados a essa finalidade. A figura (1) ilustra bem como um problema de otimização unidimensional pode ser compreendido tanto como um problema de minimização

de $f(x)$ quanto de maximização de $-f(x)$ e como em ambos os casos a derivada primeira e segunda podem ser utilizadas como informações úteis para encontrarmos o vetor de projeto unidimensional responsável pelo processo de otimização. Já a figura (1 b) ilustra como curvas de nível podem ser utilizadas para encontrarmos o ponto ótimo de uma função de duas variáveis. Aqui a analogia de caminharmos numa montanha buscando vales e picos será muito útil no desenvolvimento de métodos de otimização multidimensional sem restrições por meio de esquemas baseados no cálculo do gradiente da função objetivo.




Figura 1: Representação gráfica de um problema de otimização unidimensional (a) e de um problema de otimização bidimensional (b).

A figura (1b) mostra um ponto de ótimo no plano xy associado a um máximo ou mínimo local da função objetivo $f(x, y)$. Uma representação tridimensional um pouco mais clara desse caminho de busca, que leva em consideração aspectos topológicos da superfície que desejamos otimizar é ilustrado na figura (2). Nessa figura, o caminho azul no plano xy representa a busca do ponto ótimo da função a partir de um ponto inicial que leva em conta as características de $f(x, y)$ para ajustar a direção de busca afim de encontrar o vetor bidimensional de projeto que otimize nossa função objetivo. Nesse caso, as características da função objetivo que irão nortear o caminho de busca consistem no gradiente da função, ou seja ∇f e em sua Hessiana, cuja definição veremos mais para frente no momento em que formos apresentar métodos baseados no gradiente.

Razão áurea e otimização 1D

Um dos primeiros métodos de otimização que veremos aqui é o método da razão áurea, muito interessante para otimização unidimensional sem restrições. Esse método é análogo ao método da bissecção utilizado para identificação de raízes de funções de uma única variável. Ou seja, é um método intervalar de busca. Entretanto o que se busca aqui não é um ponto x que zere a função objetivo, mas que a otimize.

Diferentemente do método da bissecção em que utilizamos dois valores da função para definirmos um intervalo de busca inicial, aqui utilizaremos dois intervalos iniciais de busca. Isso implica na escolha inicial de três valores da função para a definição de dois intervalos iniciais ℓ_1 e ℓ_2 , ambos definidos dentro do intervalo maior ℓ_0 , de tal sorte que $\ell_0 = \ell_1 + \ell_2$.




Figura 2: Representação gráfica de uma superfície tridimensional vinculada a um função objetivo bidimensional e do caminho de busca no plano xy do ponto ótimo.

A ideia aqui é checar se o máximo ou mínimo ocorreu no intervalo ℓ_1 ou no intervalo ℓ_2 e em função disso ir diminuindo progressivamente esse intervalo.

A figura (3) ilustra como esses intervalos se relacionam com o processo de busca. Aqui começamos com um intervalo ℓ_0 para o qual assumimos a existência de um único ponto de máximo ou mínimo. Esse intervalo ℓ_0 é chamado de intervalo unimodal. Aqui para a definição do intervalo ℓ_0 precisamos apenas dos pontos x_ℓ e x_u , associados respectivamente ao limite inferior e superior do intervalo. Em seguida, dentro desse intervalo, dividimos ℓ_0 em dois intervalos ℓ_1 e ℓ_2 de tal sorte que $\ell_0 = \ell_1 + \ell_2$. Se identificarmos que o ponto de máximo ocorreu no intervalo ℓ_1 , como ilustra a figura (3) por exemplo, o próximo passo consiste em dividir ℓ_1 em dois intervalos ℓ_2 e ℓ_3 , de tal sorte que $\ell_1 = \ell_2 + \ell_3$. Uma segunda regra que aplicaremos aqui para a divisão dos intervalos é que

$$\frac{\ell_1}{\ell_0} = \frac{\ell_2}{\ell_1} = \frac{\ell_3}{\ell_2} = \frac{\ell_4}{\ell_3} = \dots = \frac{\ell_n}{\ell_{n-1}} = R. \quad (1)$$

Note que se $\ell_0 = \ell_1 + \ell_2$ e $\ell_1/\ell_0 = \ell_2/\ell_1$, então

$$\frac{\ell_1}{\ell_1 + \ell_2} = \frac{\ell_1}{\ell_2} \Rightarrow 1 + \frac{\ell_2}{\ell_1} = \frac{\ell_1}{\ell_2} \Rightarrow 1 + R = \frac{1}{R} \Rightarrow R^2 + R - 1 = 0. \quad (2)$$

Note que a raiz positiva da equação quadrática expressa em (2) é dada por

$$R = \frac{-1 + \sqrt{5}}{2} = \varphi = 0.61803... \quad (3)$$

O número φ que surge no processo é um importante número irracional, presente no mundo natural, em projetos arquitetônicos do período clássico e em estruturas matemáticas como a própria sequência de Fibonacci. Esse número define uma proporção que os gregos antigos chamavam de razão áurea, por acreditarem revelar uma proporção esteticamente perfeita. Vários templos gregos foram projetados e construídos utilizando a razão áurea como parâmetro de projeto. Por esse motivo, o método aqui descrito é conhecido como método da razão áurea.




Figura 3: Intervalos de busca de pontos de ótimo utilizados no método da razão áurea

Se pegarmos um quadrado inicial e utilizarmos a razão áurea para dividirmos esse quadrado em sub-retângulos internos, ao fazermos isso indefinidamente vamos formar uma espiral cuja razão dos comprimentos dos círculos internos vai diminuindo numa proporção que surge em diversos organismos, como plantas e animais. A figura (4) ilustra bem esse conceito. É importante notar que no nosso contexto de otimização unidimensional sem restrições a razão áurea surge como uma consequência natural dos critérios estabelecidos para a definição das divisões do intervalo inicial de busca em sub-intervalos. Afinal de contas, se vamos dividir esses intervalos de busca, precisamos de um critério objetivo para realizar a divisão. A definição desse critério por meio das equações expressas anteriormente leva naturalmente ao surgimento da razão áurea como a razão entre os intervalos de busca que vão se reduzindo à medida que avançamos no processo.

O método da interpolação quadrática

Um próximo método interessante no campo de esquemas de otimização de funções unidimensionais sem restrições é o método da interpolação quadrática. Esse método se baseia num conceito muito simples: toda parábola tem um ponto de máximo ou mínimo. De tal sorte que próximo a um mínimo ou máximo local de uma função contínua sempre poderemos ajustar uma parábola por perto, cujo máximo (ou mínimo) estará próximo do máximo (ou mínimo) local da função objetivo.

A figura (5) ilustra bem a essência do método. Nesse caso, concebemos uma parábola que possui três pontos comuns com a função objetivo $f(x)$. Esses pontos comuns são x_0, x_1, x_2 . A ideia é encontrar os coeficientes a, b, c que montam a parábola $g(x) = ax^2 + bx + c$, de tal sorte que:

$$f(x_0) = g(x_0), \quad f(x_1) = g(x_1) \quad \text{e} \quad f(x_2) = g(x_2). \quad (4)$$

Uma vez que tenhamos os valores dos coeficientes da parábola, derivamos a equação quadrática e igualamos à zero para isolar o valor x_3 do máximo ou mínimo local. Você




Figura 4: Ilustração do surgimento da razão áurea na natureza

pode tentar fazer o procedimento em casa para obter:

$$x_3 = \frac{f(x_0)(x_1^2 - x_2^2) + f(x_1)(x_2^2 - x_0^2) + f(x_2)(x_0^2 - x_1^2)}{2f(x_0)(x_1 - x_2) + 2f(x_1)(x_2 - x_0) + 2f(x_2)(x_0 - x_1)}. \quad (5)$$

Uma vez que saibamos o valor de x_3 a partir da equação (5), utilizamos os calculamos o de $f(x_3)$ e o comparamos com os valores de $f(x_0)$, $f(x_1)$ e $f(x_2)$ para atualizarmos um novo intervalo no qual novos pontos serão definidos para construção de uma próxima parábola, ainda mais próxima do ponto de máximo ou mínimo local real de $f(x)$.

Para a ideia não ficar muito abstrata, vamos a um exemplo numérico. Considere o uso da interpolação quadrática para achar o ponto de máximo da função $f(x) = 2\sin(x) - x^2/10$, abordada no problema anterior pelo método da razão áurea. Nesse caso, vamos partir dos seguintes valores iniciais $x_0 = 0$, $x_1 = 1$ e $x_2 = 4$. A substituição desses valores na equação (5) fornece $x_3 = 1.5055$. Para esses valores de x_0, x_1, x_2, x_3 calculamos $f(x_0) = 0$, $f(x_1) = 1.5829$, $f(x_2) = -3.1136$ e $f(x_3) = 1.7691$. Nesse caso temos que $f(x_1) > f(x_0)$ e $f(x_3) > f(x_1)$. Consequentemente o máximo não pode estar no intervalo $[x_0, x_1]$. Dessa forma, excluimos esse intervalo e definimos os novos três pontos da próxima parábola como $x_0 = 1$, $x_1 = 1.5055$ e $x_2 = 4$. Para esses novos valores, calculamos o novo valor de x_3 por meio da equação (5) como $x_3 = 1.4903$. E assim seguimos. É possível ver que apenas com duas iterações já estamos nos aproximando do ponto de máximo exato de $x_o = 1.4275$.




Figura 5: Representação visual dos conceitos por trás do método da interpolação quadrática

Otimização multidimensional sem restrições

No contexto em que a função objetivo é uma função de mais de uma variável, classificamos o problema de otimização como um problema multidimensional. Nessa seção iremos explorar ideias e conceitos orientados à esquemas de otimização multidimensionais sem restrições. Nesse campo, existem duas categorias gerais de métodos no campo da otimização clássica. Os métodos diretos e os métodos gradientes. A diferença principal entre essas duas categorias diz respeito ao uso que se faz da função objetivo no processo de busca por um ponto ótimo. Enquanto métodos diretos não dependem do cálculo das derivadas da função objetivo com relação ao vetor de projeto, os métodos gradientes se baseiam justamente em cálculo de derivadas multidimensionais da função objetivo para fins de otimização.

Um exemplo fácil de entendermos de um método direto é o método da busca aleatória, que se baseia na comparação do valor da função objetivo em pontos aleatórios do domínio de busca. Nesse método espalhamos pontos de forma randômica no domínio de busca, olhamos para o valor da função objetivo em cada um desses pontos, pegamos o valor máximo e vamos restringindo o domínio de busca para as imediações desse ponto ótimo. Fazendo sucessivas reduções do espaço de busca em torno de cada ponto ótimo da etapa anterior podemos encontrar pontos de máximo ou mínimo em domínios multidimensionais mesmo para funções descontínuas e de difícil diferenciação analítica.

Já os métodos gradientes utilizam de maneira inteligente a topologia da função objetivo a fim de encontrar pontos críticos mais rapidamente. Exemplos de métodos gradientes são o método do gradiente descendente ou aclave máximo, o método dos gradientes conjugados, método de Newton e de Marquardt. Veremos todos esses esquemas nesse capítulo.

Cada uma dessas abordagens possui vantagens e desvantagens. Enquanto o método da busca aleatória consegue encontrar pontos ótimos para funções objetivos extremamente complicadas e mal comportadas, o mesmo pode demorar muito tempo para encontrar esses pontos críticos. Uma vez que os métodos gradientes se baseiam no conhecimento matemático da topologia da função objetivo e usam essas informações para caminhar no

espaço de busca procurando por um ponto ótimo, é de se esperar que esses métodos sejam otimizados para encontrar rapidamente esses pontos de interesse.

Tanto os métodos diretos quanto os métodos gradientes estão associados ao que chamamos de otimização clássica. Mais recentemente, uma nova classe de métodos de otimização baseados na natureza, como os algoritmos genéticos, as redes neurais e o método do enxame de partículas, se enquadram numa classe que chamamos de métodos heurísticos ou meta-heurísticos. Esses métodos podem ser aplicados a funções descontínuas e são capazes de explorar grandes regiões de busca, mas podem ser computacionalmente bem caros.

Além das abordagens aqui citadas, existem esquemas híbridos que misturam meta-heurística com métodos gradientes. Um método recente que se vale dessa abordagem híbrida são as redes neurais informadas por física (PINN) que resolvem equações diferenciais parciais por meio do treinamento de uma grande rede neural que busca zerar localmente uma função erro associada a uma equação diferencial em pontos aleatórios de um domínio de solução. Essa técnica é interessante, pois viabiliza a realização de simulações computacionais sem a necessidade de malhas de cálculo. Nesse material iremos focar nossa atenção nos métodos clássicos de otimização baseados em gradientes.

Métodos gradientes

Antes de apresentarmos alguns dos métodos de otimização clássica baseados no cálculo dos gradientes da função objetivo, vamos recapitular alguns conceitos do nosso curso de Cálculo 3. Para isso, considere uma função de duas variáveis independentes $f(x, y)$, como representada na figura (6). Considere agora um par de coordenadas (a, b) representando




Figura 6: Ilustração de curvas de nível (a) de uma função $f(x, y)$ que pode ser imaginada como uma montanha (b)

um ponto nessa curva e um eixo h que forma um ângulo θ com relação ao eixo x a partir do ponto (a, b) como ilustrado na figura (7). Esse eixo h representará para nós uma direção inicial de busca de um ponto crítico da função $f(x, y)$. Podemos imaginar aqui a função objetivo como uma grande montanha e o eixo h representará um corte nessa montanha para caminharmos ao longo dessa direção de busca. Dessa forma, podemos imaginar que a altura da montanha na direção de busca h é uma nova função $g(h)$ que estará relacionada com a função $f(x, y)$. A inclinação dessa montanha 1D $g(h)$ a partir do ponto (a, b) é representada então por $g'(0)$. A relação entre $g'(0)$ e as derivadas parciais




Figura 7: Definição de um ponto (a, b) no plano xy e de uma direção de busca h que forma um ângulo θ com o eixo x .

de $f(x, y)$ avaliadas no ponto (a, b) é dada por:

$$g'(0) = \left(\frac{\partial f}{\partial x} \right)_{a,b} \cos(\theta) + \left(\frac{\partial f}{\partial y} \right)_{a,b} \sin(\theta). \quad (6)$$

Temos também que $\hat{e}_h = \cos(\theta)\hat{e}_x + \sin(\theta)\hat{e}_y$. Definindo o vetor gradiente ou operador ∇ como

$$\nabla = \frac{\partial}{\partial x}\hat{e}_x + \frac{\partial}{\partial y}\hat{e}_y + \frac{\partial}{\partial z}\hat{e}_z, \quad (7)$$

temos para o caso bidimensional que

$$g'(0) = \nabla f \cdot \hat{e}_h. \quad (8)$$

Além disso, temos que a direção de auge máximo em um dado ponto é dada pelo próprio gradiente de f . Dessa forma, para um campo escalar f , o gradiente de f será um campo vetorial que localmente apontará na direção de maior inclinação a partir daquele ponto. Sabemos também que no caso 1D, um ponto de máximo ou mínimo é aquele para o qual a derivada da função é nula. Mais ainda, utilizamos o sinal da segunda derivada da função para determinar se um determinado ponto crítico é um máximo ou um mínimo local. No campo das funções multidimensionais a lógica é semelhante, mas a análise pode ficar um pouco mais complicada.

Sabemos por exemplo que um ponto de máximo ou mínimo para uma função de mais de uma variável é um ponto onde o gradiente da função objetivo é zero. Entretanto, para sabermos se esse ponto é um ponto de máximo ou mínimo local, precisamos avaliar uma quantidade associada às derivadas segundas da função objetivo chamada de matriz Hessiana de f . Mais ainda, no caso multidimensional um mesmo ponto pode ser um ponto de máximo num certo sentido de busca e de mínimo no outro sentido, como ilustra a figura (8). Nesse cenário dizemos que o ponto crítico é um ponto de sela. Ele é tanto um máximo quanto um mínimo local.




Figura 8: Exemplo de uma situação em que o ponto crítico é ao mesmo tempo um máximo e um mínimo local (ponto de sela)

A matriz Hessiana: um critério para avaliação de pontos críticos

Suponha que após nossa caminhada na montanha chegamos em um ponto crítico, ou seja, encontramos as coordenadas x, y para as quais $\nabla f = \mathbf{0}$. A pergunta que queremos responder aqui é: podemos construir um critério matemático objetivo, baseado nas características topológicas de $f(x, y)$ para determinar se esse ponto crítico é um máximo local, um mínimo local ou um ponto de sela? Para respondermos essa pergunta vamos precisar definir algumas coisas. Considere no caso bidimensional a seguinte estrutura matricial

$$H = \begin{bmatrix} \frac{\partial^2 f}{\partial x^2} & \frac{\partial^2 f}{\partial x \partial y} \\ \frac{\partial^2 f}{\partial y \partial x} & \frac{\partial^2 f}{\partial y^2} \end{bmatrix} \Rightarrow \det H = |H| = \frac{\partial^2 f}{\partial x^2} \frac{\partial^2 f}{\partial y^2} - \left(\frac{\partial^2 f}{\partial x \partial y} \right)^2. \quad (9)$$

A partir dessa estrutura, conhecida como matriz Hessiana de f , podemos com base numa avaliação do sinal do determinante de H e das derivadas segundas da função objetivo com relação à x determinar a natureza do ponto crítico em questão. O critério aqui para o caso bidimensional é definido como:

- Se $|H| > 0$ e $\partial^2 f / \partial x^2 > 0$ no ponto crítico, então esse ponto é um mínimo local;
- Se $|H| > 0$ e $\partial^2 f / \partial x^2 < 0$ no ponto crítico, então esse ponto é um máximo local;
- Se $|H| < 0$ no ponto crítico, então esse ponto é um ponto de sela;

Para checar a validade desse critério para o caso bidimensional, vamos ao exemplo ilustrado pela figura (9). Essa figura mostra três funções objetivos simples, cada uma vinculada a um ponto crítico de natureza distinta.

Para o exemplo da figura (9) é fácil ver que os pontos críticos para as três funções são ocorrem no mesmo local. As três apresentam pontos críticos em $(x, y) = (0, 0)$. Verifique você mesmo agora os sinais de $|H|$ e da segunda derivada da função objetivo com relação a x e perceba a validade dos critérios estabelecidos acima.




Figura 9: Três cenários possíveis para a natureza do ponto crítico. A figura da esquerda ilustra um mínimo local, a do meio um máximo local e a da direita representa um ponto de sela.

Uma questão relevante que pode surgir é: como estender esse critério para um contexto de busca multidimensional em um espaço de dimensão $n > 2$? Nesse contexto, a representação visual de uma montanha tridimensional não é mais possível. Apesar disso, ainda podemos utilizar o critério baseado no determinante da matriz Hessiana para identificação da natureza do nosso ponto crítico. Entretanto, é mais conveniente reescrever esse critério utilizando ideias mais gerais de álgebra linear.

Considere agora então o caso mais geral possível em que a função objetivo é uma função de n variáveis definida por $f(x_1, x_2, x_3, \dots, x_n)$. Nesse caso, a matriz Hessiana de f é dada por

$$H = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix} \quad (10)$$

Pelo teorema de Schwarz, temos que as derivadas mistas são simétricas, ou seja:

$$\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i} \quad (11)$$

Assim, pela própria definição, a Hessiana é sempre uma matriz simétrica real. Essa simetria de H nos permite representar essa matriz em termos de uma matriz diagonal quando H é escrita num sistema de base formado por seus autovetores. Esse tipo de representação diagonal de uma matriz simétrica em sua base de autovetores é chamada de representação espectral de matrizes simétricas. Caso queira entender por que isso é possível, recomendamos que assista essa aula gratuita no YouTube clicando aqui. Mais ainda, quando representamos uma matriz simétrica em sua base de autovetores utilizando a representação espectral, os termos da diagonal são os autovalores da própria matriz. Esses autovalores são calculados por meio da solução de um polinômio em λ construído com base na relação

$$\det(H - \lambda I) = 0 \Rightarrow \lambda_1, \lambda_2, \lambda_3, \dots, \lambda_n. \quad (12)$$

Nesse caso mais geral, os sinais dos autovalores vão representar as curvaturas principais de f em cada direção e servirão para identificar o tipo de ponto crítico em questão. Por mais que essas informações possam parecer um pouco abstratas quando a vemos pela primeira vez, elas ilustram propriedades e características fundamentais de matrizes que

são utilizadas para descrever o comportamento de meios contínuos. Em outras palavras, o estudo formal das estruturas matemáticas por trás da descrição do comportamento de sólidos e fluidos, utiliza esses conceitos para representar por exemplo o comportamento das tensões principais e das direções de deformação principal de sólidos elásticos e outros materiais de interesse de Engenharia. Recomenda-se que aqueles que se interessarem pelo tema assistam o curso de Mecânica dos Meios Contínuos disponibilizado de forma gratuita no canal do YouTube, Ciência e Brisa.

A tabela (1) resume os critérios de avaliação da natureza do ponto crítico de uma função objetivo multidimensional em termos da análise dos sinais dos autovalores de f .

Item	Significado
Autovalores da Hessiana	Curvaturas principais de f em cada direção
Sinais dos autovalores	Classificam o tipo de ponto crítico
Todos positivos	Mínimo local
Todos negativos	Máximo local
Sinais mistos	Ponto de sela
Algum autovalor nulo	Teste inconclusivo

Tabela 1: Critérios de avaliação da natureza de um ponto crítico para uma função objetivo multidimensional em termos dos sinais dos autovalores da matriz Hessiana de f

Para o assunto não ficar muito abstrato, vamos a um exemplo de aplicação. Considere então a função:

$$f(x, y, z) = x^2 + y^2 - z^2$$

Nesse caso, o **gradiente** de f é dado por:

$$\nabla f(x, y, z) = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \\ \frac{\partial f}{\partial z} \end{bmatrix} = \begin{bmatrix} 2x \\ 2y \\ -2z \end{bmatrix}$$

É fácil perceber que aqui o ponto crítico ocorre em $(x, y, z) = (0, 0, 0)$. Dessa forma, a **matriz Hessiana** de f no ponto crítico é dada por

$$H_f(x, y, z) = \begin{bmatrix} \frac{\partial^2 f}{\partial x^2} & \frac{\partial^2 f}{\partial x \partial y} & \frac{\partial^2 f}{\partial x \partial z} \\ \frac{\partial^2 f}{\partial y \partial x} & \frac{\partial^2 f}{\partial y^2} & \frac{\partial^2 f}{\partial y \partial z} \\ \frac{\partial^2 f}{\partial z \partial x} & \frac{\partial^2 f}{\partial z \partial y} & \frac{\partial^2 f}{\partial z^2} \end{bmatrix} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & -2 \end{bmatrix}$$

Faça o teste em casa e mostre que para esse exemplo os **autovalores** da Hessiana são dados por

$$\lambda_1 = 2, \quad \lambda_2 = 2, \quad \lambda_3 = -2.$$

De acordo com os critérios estabelecidos na tabela (1), como a matriz Hessiana possui dois autovalores positivos e um negativo, o ponto crítico é um **ponto de sela**. A tabela (2) apresenta um resumo da análise realizada para este exemplo. Como no nosso exemplo escolhemos uma função de 3 variáveis, não conseguimos representá-la em termo de uma curva tridimensional. Mas podemos fazer alguns cortes em planos específicos para avaliar o comportamento dessa função. A figura (10) mostra que essa função apresenta o comportamento de um parabolóide elíptico no plano z e de pontos de sela nos planos x e y .

Item	Descrição
Função	$f(x, y, z) = x^2 + y^2 - z^2$
Ponto crítico	$(0, 0, 0)$
Gradiente no ponto	$\nabla f = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$
Hessiana no ponto	$H = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & -2 \end{bmatrix}$
Autovalores	$\lambda_1 = 2, \lambda_2 = 2, \lambda_3 = -2$
Classificação	Ponto de sela (Hessiana indefinida)

Tabela 2: Resumo da análise da natureza do ponto crítico para a função $f(x, y, z) = x^2 + y^2 - z^2$




Figura 10: Comportamento nos planos z, y, x da função $f(x, y, z) = x^2 + y^2 - z^2$

O método do aclave máximo

O primeiro método baseado no cálculo do gradiente que iremos apresentar aqui é o método do aclave máximo. A ideia desse método é caminhar uma certa distância h^* ao longo da direção do gradiente a partir de um ponto inicial. Em seguida, para-se e faz-se uma nova avaliação de direção para ajustar a caminhada na direção do gradiente a partir do novo ponto de parada. O processo é realizado algumas vezes até atingirmos o ponto ótimo. Para entendermos a essência do método do aclave máximo façamos um exemplo. Considere então a função objetivo $f(x, y) = 2xy + 2x - x^2 - 2y^2$ e um ponto inicial $(x_0, y_0) = (-1, 1)$. O primeiro passo do processo é tentar definir uma função $g(h)$ que seja idêntica à função $f(x, y)$ na direção do gradiente a partir de (x_0, y_0) . Esse procedimento é chamado de parametrização e consiste na aplicação das seguintes relações

$$x = x_0 + h \left(\frac{\partial f}{\partial x} \right)_{x_0, y_0} \quad \text{e} \quad y = y_0 + h \left(\frac{\partial f}{\partial y} \right)_{x_0, y_0}. \quad (13)$$

Para nossa função objetivo deste exemplo temos que $(\partial f / \partial x)_{x_0, y_0} = 6$ e $(\partial f / \partial y)_{x_0, y_0} = -6$, de tal sorte que nossas relações paramétricas são dadas por $x = -1 + 6h$ e $y = 1 - 6h$. Essas relações são então substituídas na função $f(x, y)$:

$$f(x, y) = 2(-1 + 6h)(1 - 6h) + 2(-1 + 6h) - (-1 + 6h)^2 - 2(1 - 6h)^2 = g(h). \quad (14)$$

Aplicando a distributiva entre todos os termos em parênteses e reorganizando em potência de h temos o seguinte polinômio para $g(h)$:

$$g(h) = -180h^2 + 72h - 7. \quad (15)$$

O próximo passo é definir a distância h^* que devemos percorrer no sentido $\hat{e}_h$ ao longo do corte da nossa montanha $f(x, y)$ representado por $g(h)$. No método do aclave máximo a escolha consiste em caminhar até um máximo local em $g(h)$. Para isso, precisamos encontrar o valor h^* que faça com que $g'(h^*) = 0$. Derivando a equação (15), igualando à zero e isolando o valor de h , obtemos $h^* = 0.2$. Nesse momento voltamos às equações paramétricas e atualizamos o valor do próximo ponto x, y a partir do ponto inicial x_0, y_0 :

$$x = -1 + 0.2 \left(\frac{\partial f}{\partial x} \right)_{x_0, y_0} = 0.2 \quad \text{e} \quad y = 1 + 0.2 \left(\frac{\partial f}{\partial y} \right)_{x_0, y_0} = -0.2. \quad (16)$$

A figura (11) mostra esse primeiro passo da caminhada. Note que já estamos chegando mais perto do ponto crítico. O próximo passo consiste em descobrir a nova curva $g(h)$ a partir desse ponto de parada e repetir o processo. Faça isso em casa e veja como a caminhada evolui na direção do ponto crítico.




Figura 11: Primeiro passo no exemplo do método do aclave máximo para a função objetivo $f(x, y) = 2xy + 2x - x^2 - 2y^2$ com o detalhe da curva $g(h)$ ao lado.

Atividade para Casa #4 (APC)

Para a função objetivo multidimensional definida no exemplo anterior, você deverá

- Calcular na mão 5 iterações do método do aclave máximo, partindo do ponto inicial $(x_0, y_0) = (-2, 3)$;
- Registrar todos os pares (x, y) a partir do ponto inicial, de tal sorte que além do ponto inicial, você tenha 5 pontos adicionais mostrando o caminho no plano xy percorrido ao longo da busca;
- Construir para esses 6 pontos totais 5 vetores bidimensionais indicando as direções de busca a cada passo da caminhada;
- Normalizar esses vetores e mostrar o valor do produto escalar entre duas direções sucessivas de busca;

Observação: Esta atividade deve ser desenvolvida de forma analítica (papel e lápis), podendo também ser digitada em $\text{\LaTeX}$ e entregue em formato PDF (preferencialmente), ou escaneada a partir de anotações feitas no papel, desde que o estudante possua uma caligrafia legível e uma organização clara na apresentação das ideias.

O método dos gradientes conjugados

Se você fez o passo seguinte do exemplo dado na seção anterior para otimização da função $f(x, y) = 2xy + 2x - x^2 - 2y^2$ pelo método do aclave máximo e chegou a marcar no mapa essa nova coordenada, deve ter percebido que ela parece fazer um ângulo de 90 graus com relação à caminhada do passo anterior. De fato, quando utilizamos o método do aclave máximo, teremos sempre um ângulo reto sendo formado por dois passos sucessivos no processo de busca, o que pode levar a um processo lento de encontro do ponto ótimo da função objetivo. Esse processo de busca em zigue-zague pode demorar muito para encontrar o ponto crítico dependendo das características da função que desejamos otimizar. Por conta disso, alguns métodos mais robustos podem ser aplicados ao processo de otimização, como é o caso do método dos gradientes conjugados.

Mas antes de adentrarmos na ideia do método dos gradientes conjugados, vamos demonstrar aqui a ortogonalidade entre direções sucessivas de busca associada à aplicação do método do aclave máximo. Para isso, considere que a nossa função objetivo é uma função quadrática, do tipo

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T A \mathbf{x} - \mathbf{b}^T \mathbf{x}, \quad (17)$$

em que $A \in \mathbb{R}^{n \times n}$ é uma matriz simétrica definida positiva e $\mathbf{b} \in \mathbb{R}^n$. A ideia de utilizarmos aqui uma função objetivo quadrática se deve ao fato de que parábolas são ótimas candidatas a funções aproximadoras do comportamento de funções nas vizinhanças de pontos ótimos. Para esse cenário, se tomamos o gradiente da função f , podemos mostrar que

$$\nabla f(\mathbf{x}) = A\mathbf{x} - \mathbf{b} = 0, \quad (18)$$

ou seja, o problema de otimização de uma função objetivo quadrática é equivalente ao problema de resolvermos um sistema linear. Por conta disso, o método dos gradientes conjugados é não só um método para solução de problemas de otimização multidimensional sem restrições, como também é um método aplicado à solução de sistemas lineares. Podemos então afirmar que o ponto $\mathbf{x}^*$ que minimiza f é a solução do sistema linear:

$$A\mathbf{x} = \mathbf{b}. \quad (19)$$

Agora, dado um ponto inicial $\mathbf{x}_0$, o método do aclave máximo caminha no sentido de busca do ponto ótimo por meio da relação:

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \alpha_k \nabla f(\mathbf{x}_k), \quad (20)$$

em que α_k equivale ao nosso h^* no passo k e pode ser dado por

$$\alpha_k = \arg \min_{\alpha} f(\mathbf{x}_k - \alpha \nabla f(\mathbf{x}_k)). \quad (21)$$

Mas nós sabemos que

$$\nabla f(\mathbf{x}_k) = A\mathbf{x}_k - \mathbf{b}, \quad \text{e} \quad \mathbf{x}_{k+1} = \mathbf{x}_k - \alpha_k \nabla f(\mathbf{x}_k), \quad (22)$$

de tal sorte que

$$\nabla f(\mathbf{x}_{k+1}) = A\mathbf{x}_{k+1} - \mathbf{b} = A(\mathbf{x}_k - \alpha_k \nabla f(\mathbf{x}_k)) - \mathbf{b} = \nabla f(\mathbf{x}_k) - \alpha_k A \nabla f(\mathbf{x}_k). \quad (23)$$

Para mostrarmos a ortogonalidade entre $\nabla f(\mathbf{x}_k)$ e $\nabla f(\mathbf{x}_{k+1})$ precisamos calcular o seguinte produto interno:

$$\begin{aligned} \nabla f(\mathbf{x}_{k+1})^T \nabla f(\mathbf{x}_k) &= (\nabla f(\mathbf{x}_k) - \alpha_k A \nabla f(\mathbf{x}_k))^T \nabla f(\mathbf{x}_k) \\ &= \|\nabla f(\mathbf{x}_k)\|^2 - \alpha_k \nabla f(\mathbf{x}_k)^T A \nabla f(\mathbf{x}_k) \end{aligned} \quad (24)$$

Para encontrarmos o valor ótimo de α_k substituímos a expressão para $\mathbf{x}_{k+1}$ obtida em (20) na expressão para a função objetivo quadrática, definida em (17), derivamos o resultado com relação à α_k , igualamos à zero e descobrimos o valor de α_k que minimiza o gradiente no caminho da direção de busca. Esse valor é dado por

$$\alpha_k = \frac{\nabla f(\mathbf{x}_k)^T \nabla f(\mathbf{x}_k)}{\nabla f(\mathbf{x}_k)^T A \nabla f(\mathbf{x}_k)}. \quad (25)$$

Substituindo a equação (25) em (24) obtemos:

$$\nabla f(\mathbf{x}_{k+1})^T \nabla f(\mathbf{x}_k) = \|\nabla f(\mathbf{x}_k)\|^2 - \frac{(\nabla f(\mathbf{x}_k)^T \nabla f(\mathbf{x}_k))^2}{\nabla f(\mathbf{x}_k)^T A \nabla f(\mathbf{x}_k)} = 0, \quad (26)$$

provando assim a ortogonalidade entre direções sucessivas de busca quando utilizamos o método do aclave máximo. A fim de resolver esse problema de busca em zigue-zague, o método dos gradientes conjugados propõe que duas direções sucessivas de busca $\mathbf{p}_i$ e $\mathbf{p}_j$ devam ser mutuamente conjugadas entre si para fugir desse problema. Dizemos então que essas duas direções são chamadas de **conjugadas com respeito à matriz A** se

$$\mathbf{p}_i^T A \mathbf{p}_j = 0 \quad \text{para } i \neq j \quad (27)$$

Essa propriedade é mais geral do que o conceito de ortogonalidade euclidiana e está relacionada à curvatura da função objetivo quadrática

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T A \mathbf{x} - \mathbf{b}^T \mathbf{x}$$

Mas como essa imposição de conjugação mútua entre direções sucessivas de busca leva a uma busca mais retilínea em direção ao ponto ótimo do que aquela em zigue-zague observada no método do aclave máximo? Para responder a essa pergunta, precisamos definir aqui como o método dos gradientes conjugados é construído para além da restrição de conjugação mútua. Nesse método, a direção de busca é atualizada pela relação:

$$\mathbf{p}_{k+1} = -\nabla f_{k+1} + \beta_k \mathbf{p}_k \quad (28)$$

com β_k sendo um parâmetro minimizador. Aqui entra uma característica importante do método dos gradientes conjugados. Podemos escolher um parâmetro minimizador de diferentes maneiras, ou seja, existem variantes do método dos gradientes conjugados, como por exemplo, o algoritmo de Fletcher-Reeves, no qual

$$\beta_k = \frac{\|\nabla f_{k+1}\|^2}{\|\nabla f_k\|^2}.$$

Vamos verificar agora então como essa nova forma de caminhar rumo a um ponto crítico impacta na ortogonalidade entre direções sucessivas de busca. Para isso precisamos checar se

$$\mathbf{p}_{k+1}^T \mathbf{p}_k \neq 0.$$

Essa verificação é razoavelmente simples, para isso basta substituírmos a expressão das direções de busca do método dos gradientes conjugados para obter:

$$\mathbf{p}_{k+1}^T \mathbf{p}_k = (-\nabla f_{k+1} + \beta_k \mathbf{p}_k)^T \mathbf{p}_k = -\nabla f_{k+1}^T \mathbf{p}_k + \beta_k \|\mathbf{p}_k\|^2$$

Para a ortogonalidade ser verdadeira, precisaríamos que

$$\beta_k = \frac{\nabla f_{k+1}^T \mathbf{p}_k}{\|\mathbf{p}_k\|^2}, \quad (29)$$

o que significa que qualquer valor de β_k definido de maneira diferente ao que expressa a equação (29) implicaria na não-ortogonalidade entre duas direções sucessivas de busca. É fácil verificar por exemplo que a variante de Fletcher-Reeves para o parâmetro minimizador β_k leva a um caminhar não ortogonal entre direções sucessivas ao longo da busca do ponto ótimo. Mas uma pergunta continua em aberto: como escolher um valor de β_k que atenda à exigência de conjugação mútua entre direções sucessivas de busca com relação à matriz A ? Para isso, precisamos testar a conjugação mútua com base nas definições do método:

$$\mathbf{p}_{k+1}^T A \mathbf{p}_k = (-\nabla f_{k+1} + \beta_k \mathbf{p}_k)^T A \mathbf{p}_k = -\nabla f_{k+1}^T A \mathbf{p}_k + \beta_k \mathbf{p}_k^T A \mathbf{p}_k. \quad (30)$$

A partir da equação (30) é possível descobrir o valor de β_k que garante conjugação mútua, dado por:

$$\beta_k = \frac{\nabla f_{k+1}^T A \mathbf{p}_k}{\mathbf{p}_k^T A \mathbf{p}_k}. \quad (31)$$

Neste caso, ao utilizarmos o valor de β_k definido em (31) obtemos

$$\mathbf{p}_{k+1}^T A \mathbf{p}_k = 0 \Rightarrow \text{direções são } A\text{-conjugadas.}$$

O problema de utilizarmos esse valor de β_k dentro de um código numérico voltado à otimização de uma função multidimensional num contexto sem restrições é que a cada passo precisamos realizar o produto da matriz dos coeficientes pela direção de busca e esse procedimento pode se tornar computacionalmente caro quando as dimensões do espaço de busca aumentam. Por conta disso, alguns autores desenvolveram fórmulas alternativas para a determinação do parâmetro minimizador que são mais baratas computacionalmente e satisfazem de forma aproximada a condição de conjugação mútua, como é o caso do algoritmo de Fletcher-Reeves.

No contexto da variante de Fletcher-Reeves do método dos gradientes conjugados temos que as direções de busca evoluem de acordo com a seguinte expressão

$$\mathbf{p}_{k+1} = -\nabla f_{k+1} + \beta_k \mathbf{p}_k \quad \text{e} \quad \beta_k = \frac{\nabla f_{k+1}^T \nabla f_{k+1}}{\nabla f_k^T \nabla f_k}. \quad (32)$$

Para checarmos se as direções de busca são mutuamente conjugadas nesse método, precisamos avaliar se $\mathbf{p}_k^T A \mathbf{p}_{k+1} = 0$. Para isso, fazamos

$$\mathbf{p}_k^T A \mathbf{p}_{k+1} = -\mathbf{p}_k^T A \nabla f_{k+1} + \beta_k \mathbf{p}_k^T A \mathbf{p}_k \quad \text{com} \quad \nabla f_{k+1} = \nabla f_k + \alpha_k A \mathbf{p}_k \quad (33)$$

logo

$$\mathbf{p}_k^T A \mathbf{p}_{k+1} = -\mathbf{p}_k^T A \nabla f_k - \alpha_k \mathbf{p}_k^T A^2 \mathbf{p}_k + \beta_k \mathbf{p}_k^T A \mathbf{p}_k, \quad (34)$$

com

$$\alpha_k = \frac{\nabla f_k^T \nabla f_k}{\mathbf{p}_k^T A \mathbf{p}_k}, \quad \beta_k = \frac{\nabla f_{k+1}^T \nabla f_{k+1}}{\nabla f_k^T \nabla f_k}. \quad (35)$$

Se assumirmos que a função objetivo é quadrática e que as operações numéricas envolvendo a matriz A são computadas com aritmética exata (sem erros de arredondamento) é possível provar nesse caso que $\mathbf{p}_k^T A \mathbf{p}_{k+1} = 0$. Isso significa que para funções objetivo não quadráticas ou em contextos nos quais o espaço de busca possui um número elevado de dimensões de tal sorte que erros numéricos de arredondamento possam se propagar, o método de Fletcher-Reeves pode não garantir a conjugação mútua entre direções sucessivas de busca. Esse fenômeno é chamado de degradação da conjugação mútua e pode levar a uma eventual busca em zigue-zague do nosso ponto crítico.

Programa para Casa #4 (PPC)

Escreva um programa que resolva um problema de **maximização** de duas variáveis utilizando dois métodos diferentes:

1. **Acrive Máximo** (steepest ascent);
2. **Gradientes Conjugados (Fletcher-Reeves)**.

A função a ser maximizada é:

$$f(x, y) = 2xy + 2x - x^2 - 2y^2,$$

cujo ótimo analítico é $(x^*, y^*) = (2, 1)$ com $f^* = 2$.

O método do acrive máximo utiliza a direção:

$$p = \nabla f = \left(\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right),$$

enquanto o método dos gradientes conjugados (Fletcher-Reeves) atualiza a direção de busca como:

$$p_{k+1} = \nabla f_{k+1} + \beta_k p_k, \quad \beta_k = \frac{|\nabla f_{k+1}|^2}{|\nabla f_k|^2}.$$

Ambos os métodos deverão utilizar a mesma **linha de busca unidimensional** baseada em interpolação quadrática de três pontos, com opção de *fallback* caso o denominador da fórmula do vértice se torne muito pequeno.

O programa deve solicitar ao usuário os valores iniciais (x_0, y_0) e executar as duas estratégias em sequência, salvando as saídas em arquivos distintos:

- `output1.dat` — log do método do acrive máximo;
- `output2.dat` — log do método dos gradientes conjugados;
- `function.dat` — amostras de (x, y, f) para plotar as curvas de nível.

O formato de cada linha dos arquivos de log deverá ser:

```
iter erro h x y dfx dfy.
```

Durante a execução, o programa deve imprimir na tela, a cada iteração:

- o número da iteração;
- os valores atuais de (x, y) e $f(x, y)$;
- o valor do passo h e o erro (módulo do gradiente).

A convergência esperada é para $(x, y) \approx (2, 1)$ e $f \approx 2$, com erro $|\nabla f|$ decaindo até a tolerância definida.

Para a interpolação quadrática na linha de busca, utilize a mesma fórmula do vértice já estudada anteriormente, garantindo que:

$$h^* = \frac{1}{2} \frac{(h_0^2 - h_2^2)g(h_1) + (h_2^2 - h_1^2)g(h_0) + (h_1^2 - h_0^2)g(h_2)}{(h_0 - h_2)g(h_1) + (h_2 - h_1)g(h_0) + (h_1 - h_0)g(h_2)}.$$

Se a parábola for degenerada, adote como passo o melhor entre (h_0, h_1, h_2) . Ao final, gere um gráfico com as curvas de nível de $f(x, y)$ e as trajetórias de cada método sobrepostas, diferenciando-as por cor ou símbolo. O programa deverá mostrar claramente a diferença entre o comportamento do **Aclive Máximo**, que tende a “zigzaguear”, e o **Gradientes Conjugados (FR)**, que tende a ir mais direto ao ponto.

Medite sobre o efeito do ponto inicial (x_0, y_0) sobre a trajetória e a eficiência dos métodos.

Requisitos de implementação:

- O código deve ser implementado a partir dos conceitos desenvolvidos pelo aluno, não sendo permitido o uso de bibliotecas que realizem diretamente a integração numérica;
- É permitido o uso de estruturas básicas da linguagem, como vetores, matrizes, funções, laços e condicionais;
- O código deve estar devidamente comentado e organizado;
- Os resultados devem ser apresentados de forma clara, incluindo gráficos e análises.

Entrega:

- O código deverá ser enviado pelo ambiente Aprender3;
- O programa deverá ser disponibilizado em repositório próprio no GitHub, acompanhado de documentação adequada (README.md);
- A documentação deverá permitir que terceiros compreendam, executem e reproduzam os resultados obtidos.

Referências bibliográficas

1. S. C. Chapra, R. P. Canale. “Métodos Numéricos para Engenharia.”, McGrawHill, 5a edição (2008): 1-825.
2. R. G. Gontijo, “Notas de aula do curso de Cálculo Numérico Aplicado”, (2026).